

HW1 — derivations

Network input [B, 3, S, S], S divisible by 16, FP32, eval + inference mode, 100 classes.

1. Output resolution

General formula, stride-1 and stride-2 cases:

$$H_{out} = \frac{H + 2p - k + 1}{s}, \quad p = \frac{k}{2}$$

stride 1, odd k: $H_{out} = H$

stride 2, even H: $H_{out} = \frac{H-1}{2} + 1 = \frac{H}{2}$

layer	$C_{in} \rightarrow C_{out}$	k, stride, pad	output side
conv1	$3 \rightarrow 32$	$7, 2, 3$	$\frac{5}{2}$
maxpool	32	$3, 2, 1$	$\frac{5}{4}$
conv2	$32 \rightarrow 64$	$5, 1, 2$	$\frac{5}{4}$
conv3	$64 \rightarrow 128$	$3, 2, 1$	$\frac{5}{8}$
conv4	$128 \rightarrow 256$	$1, 1, 0$	$\frac{5}{8}$
conv5	$256 \rightarrow 256$	$3, 2, 1$	$\frac{5}{16}$
conv6	$256 \rightarrow 512$	$4, 1, 0$	$\frac{5}{16}$
GAP	512	—	1
fc1, ReLU, fc2	$512 \rightarrow 256 \rightarrow 100$	—	—

2. FLOPs

Convention and the Conv / Linear formulas:

$$F_{\text{conv}} = 2 \cdot B \cdot M_{\text{out}} \cdot W_{\text{out}} \cdot C_{\text{out}} \cdot C_{\text{in}} \cdot k^2 \quad F_{\text{linear}} = 2 \cdot B \cdot n_{\text{in}} \cdot n_{\text{out}}$$

layer	expression	result
conv1	$2 \cdot \left(\frac{S}{2}\right)^2 \cdot 32 \cdot 3 \cdot 43$	$2352 \cdot B \cdot S^2$
conv2	$2 \cdot \left(\frac{S}{4}\right)^2 \cdot 64 \cdot 32 \cdot 25$	$6400 \cdot B \cdot S^2$
conv3	$2 \cdot \left(\frac{S}{8}\right)^2 \cdot 128 \cdot 64 \cdot 9$	$2304 \cdot B \cdot S^2$
conv4	$2 \cdot \left(\frac{S}{8}\right)^2 \cdot 256 \cdot 128$	$1024 \cdot B \cdot S^2$
conv5	$2 \cdot \left(\frac{S}{16}\right)^2 \cdot 256 \cdot 256 \cdot 9$	$4608 \cdot B \cdot S^2$
conv6	$2 \cdot \left(\frac{S}{16}\right)^2 \cdot 512 \cdot 256$	$1024 \cdot B \cdot S^2$
fc1	$2 \cdot 512 \cdot 256$	$262144 \cdot B$
fc2	$2 \cdot 256 \cdot 100$	$51200 \cdot B$
sum		$17712 \cdot B \cdot S^2 + 313344 \cdot B$

FLOPs(S, B), profiler check, extended operation count:

$$FLOPs(S, B) = 17712 \cdot B \cdot S^2 + 313344 \cdot B$$

• ReLU Conv out: $8 + 4 + 2 + 4 + 4 + 2 = 24 \cdot B \cdot S^2$

• Max Pool $3 \cdot 3$: 8 conv out , $2 \cdot B \cdot S^2 \Rightarrow 16 \cdot B \cdot S^2$

$$Ops_{\text{ent}}(S, B) = FLOPs(S, B) + 57 \cdot B \cdot S^2 + 256 \cdot B$$

3. Parameters

layer	count
conv1	$3 \cdot 32 \cdot 49 = 4804$
conv2	$32 \cdot 64 \cdot 25 = 51200$
conv3	$64 \cdot 128 \cdot 9 = 73728$
conv4	$128 \cdot 256 = 32768$

layer	count
conv5	$256 \cdot 256 \cdot 9 = 589824$
conv6	$256 \cdot 512 = 131072$
fc1	$512 \cdot 256 + 256 = 131328$
fc2	$256 \cdot 100 + 100 = 25700$

$P = 1040324$ param., $4P = 4161296$ bytes

* Без Batch Norm; convs без bias

4. Peak memory

Quantity measured and assumptions: torch.cuda.max_memory_allocated()

во время одного forward pass (FP)
(input tensor уже загружен в память)

- Param модели и bias тензор x хранятся в памяти весь FP-тик. который хранится x
- Во время выч. операции in и out одновременно хран в памяти
- ReLU вычисл in-place

Live elements per operator (units of $B \cdot S^2$):

operator	live tensors	total
conv1	$x + out(8)$	11
maxpool	$x + conv1(8) + out(2)$	13
conv2	$x + pool(2) + out(4)$	9
conv3	$x + 4 + 2$	9
conv4	$x + 2 + 4$	9
conv5	$x + 4 + 4$	8
conv6	$x + 1 + 2$	6

head	$O(B)$	—
------	--------	---

Tensor-lifetime peak, MaxPool index allocation, Memory(S, B):

$K_{on} \rightarrow B_0$ $3n+B$ параметров.

$$B \cdot S^2$$

$$K=3$$

$[B, 3, S, S]$ содержит $2BS^2$ байт

Можно временно хранить Тензоры:

$$M_{naive} = 4 \cdot (P + 13 \cdot B \cdot S^2)$$

P, Torch CUDA при работе max-pool 2d с

max-pool2d-with-indices c int64 out size

MaxPool: $2 \cdot B \cdot S^2$

T.K int64 8 байт:

$$2 \cdot B \cdot S^2 \cdot 8 = 16 \cdot B \cdot S^2$$

Due FP32:

$$\frac{16 \cdot B \cdot S^2}{4} = 4 \cdot B \cdot S^2$$

Пик памяти:

$$B + 4 = 14 \cdot B \cdot S^2 \Rightarrow$$

$$\Rightarrow \text{Memory}(S, B) = 4P + 68 \cdot B \cdot S^2, \text{ т.к. } 4P = 4161296 \text{ байт}$$

$$\Rightarrow \text{Memory}(S, B) = 4161296 + 68 B \cdot S^2$$

5. Bytes moved (logical traffic)

Assumptions:

operator	read	write	sum
conv1	3	8	11
relu1 (inplace)	8	8	16
maxpool	8	2	10
conv2 + relu	2+4	4+4	14
conv3 + relu	4+2	2+2	10
conv4 + relu	2+4	4+4	14
conv5 + relu	4+1	1+4	10
conv6 + relu	1+2	2+2	7
GAP	2	—	2
sum			91

Head (per image), weights, Bytes(S, B):

$$\text{Bytes}(S, B) = 4 \cdot (P + 91 \cdot B \cdot S^2 + 2148 \cdot B)$$

6. Latency

$T(S, B)$, assumptions, fitting, regimes, limitation of the model:

$$T(S, B) = t_0 + \max\left(\frac{B_{bytes}(S, B)}{BW}, \frac{FLOPs(S, B)}{R}\right)$$

где:

- t_0 - sum overhead: значения CUDA-ядро, Python, диспетчер
- BW (bytes/s) - скорость переноса данных
- R (FLOPs) - скорость вычислений
- * BW и R - значения модели и значения (тест GPU)

ОГРАНИЧЕННАЯ МОДЕЛЬ:

$$B \cdot S^2 \rightarrow \text{inf}: \frac{FLOPs}{B_{bytes}} \rightarrow \frac{17412}{4.77} \approx 48.7 \text{ FLOP/byte}$$

$$t_0 = 2.97 \cdot 10^{-4} \text{ sec}$$

$$BW = 3.01 \cdot 10^{11} \text{ bytes/s}$$

$$R = 1.38 \cdot 10^{13} \text{ FLOPs}$$

4. Energy:

$$E(S, B) = P_0 \cdot T(S, B) + e_f \cdot FLOPs(S, B) + e_b \cdot B_{bytes}(S, B)$$

$P_0, e_f, e_b \geq 0$

Fitted: $t_0 = \underline{2.97 \cdot 10^{-4}} \text{ s}$ $BW = \underline{3.01 \cdot 10^{11}} \text{ bytes/s}$ $R = \underline{1.38 \cdot 10^{13}} \text{ FLOP/s}$

$e_f [J/FLOPs]$ - суммарное энергопотребление на 1 FLOP

$e_b [J/byte]$ - суммарное энергопотребление на 1 байт

$P_0 [W]$ - эффект мощности